Eric Marcon

R: Créer un package

Eric Marcon

02 mai 2018

Cadre

Outil diffusable

Trois fois le même code : écrire une fonction.

Trois utilisations de la même fonction : écrire un package.

Formalisme

Standardisation du code.

Vérifications.

Documentation obligatoire.

Outils

devtools et *roxygen2* simplifient le travail.

Création d'un package

Conception

A quoi va servir le package ?

- Consolidation de sa recherche : le package rassemble et organise des méthodes. Exemples : *entropart*, *ade4*.
- Outil d'intérêt général. Exemples : *EcoFoG*, *vegan*, *spatstat*, *ggplot2*.

Un package ne doit traiter qu'un sujet. Si nécessaire, écrire plusieurs packages.

Exemple travaillé

Package *multiple* :

- des fonctions : `Double(x)`, `Triple(x)` et `Multiple(x, n)`... pour calculer des multiples.
- des fonctions comme `FuzzyDouble(x)` pour calculer des multiples avec un bruit.
- une représentation graphique du multiple en fonction de `x` (une droite).

Création

Le package est créé dans le dossier indiqué.

```
devtools::create(path = "multiple")
```

Le dossier final a le nom du package.

Ouvrir le projet du package.

Etudier les fichiers créés.

DESCRIPTION

```
Package: multiple
Title: Compute multiples
Version: 0.0.0.9000
Authors@R: person("First", "Last", email =
  "first.last@example.com", role = c("aut", "cre"))
Description: Efficiently calculate multiples of numbe
  following Me et al. (2018).
Depends: R (>= 3.4.3)
License: GNU General Public License
Encoding: UTF-8
LazyData: true
```

Fonctions

Code dans des fichiers .R

Organisation libre, les fichiers ne seront pas dans le package.

Choix :

- un fichier `Project.R` pour le code commun à tout le package
- un fichier R par groupe de fonctions, ici : `Double.R` et `FuzzyDouble.R`

Project.R

Eric Marcon

Code commun

```
#' multiple
#'
#' Exercise package
#'
#' @name multiple
#' @docType package
#' @import ggplot2  # Erreur volontaire
NULL
```

Première version de `Double(x)`

```
Double <- function(number) {
    return(2 * number)
}
```

Exécuter le code pour charger la fonction en mémoire.

Tester.

Eric Marcon

Documenter

Insert Roxygen sleleton :

```
#' Double
#'
#' Compute the Double value of a vector
#'
#' The Double is calculated by multiplying each value
#'
#' @param number A numeric vector
#'
#' @return A vector containing the Double values.
#' @export
#'
#' @examples
#' Double(runif(3))
```

Double() est exportée.

Oxygéner et installer

Build Source package : crée multiple_0.0.0.9000.tar.gz avec sa documentation.

Etudier le contenu de `man`

Charger le package :

- Nettoyer l'environnement (fonctions en mémoire)
- *Install and Restart*

```
?multiple
```

Vérifier le package

Check

```
(...)
checking package dependencies ... ERROR
Namespace dependency not required: 'ggplot2'

(...)
R CMD check results
1 error  | 0 warnings | 0 notes
```

Corriger *toutes* les erreurs, avertissements et notes.

Ecrire un générique

Problème : `Double()` transforme les entiers en réels.

```
str(Double(1L))
```

```
##  num 2
```

Solution :

```
str(1L * 2L)
```

```
##  int 2
```

Ecrire un générique

```
Double <- function(x, ...) {
    UseMethod("Double")
}
Double.default <- function(x, ...) {
    return(2 * x)
}
Double.integer <- function(x, ...) {
    return(2L * x)
}
```

Exécuter et tester.

```
str(Double(2L))
```

```
##  int 4
```

Remarquer : le respect de la signature, obligatoire.

Documenter

Un seul fichier d'aide : `@name` et `@rdname`

```
#' Double
(...)
#' @param x A vector
#' @param ... Unused
(...)
#' @name Double
#NULL

#' @rdname Double
#' export
Double <- function(x, ...) {
  UseMethod("Double")
}
```

Documenter

Les méthodes S3 doivent être déclarées, pas exportées mais Roxygen exige `@export` pour la déclaration.

```
#' @rdname Double
#' @method Double default
#' @export
Double.default <- function(x) {
  return(2*x)
}

#' @rdname Double
#' @method Double integer
#' @export
Double.integer <- function(x) {
  return(2L*x)
}
```

Traiter les erreurs

`Double.default()` peut revevoir un objet non numérique.

```
Double.default <- function(x) {
    # Input check
    if (!is.numeric(x))
        stop("Double requires a numeric object")
    # Compute and return
    return(2 * x)
}
```

Tester après *Install and Restart* (Oxygénation inutile).

Que se passe-t-il si `x` est une matrice ?

```
#' @param x An object
```

Double avec bruit

Objectif : écrire une fonction double, avec un terme d'erreur normal, qui retourne un data.frame avec `x` et son double, facile à dessiner.

La fonction va dans un nouveau fichier : `FuzzyDouble.R`

Ecrire la fonction et la tester en la sourçant.

Fonction

```
FuzzyDouble <- function(x, mean = 0, sd = 1) {
    # Double x and add normal error
    y <- 2 * x + stats::rnorm(n = length(x), mean = mean,
        sd = sd)
    # Make a data.frame
    fuzzydouble <- data.frame(x = x, y = y)
    # Make it a FuzzyMultiple object
    class(fuzzydouble) <- c("FuzzyDouble", class(fuzzydouble))
    return(fuzzydouble)
}
```

Remarquer :

- `stats::rnorm()` ; Classe ;
- Commentaires

Fonction

Ne pas oublier les tests !

```
FuzzyDouble <- function(x, mean = 0, sd = 1) {
    # Input check
    if (!is.numeric(x))
        stop("Double requires a numeric object")
    if (!is.numeric(mean))
        stop("The mean noise must be numeric")
    if (!is.numeric(sd))
        stop("The standard deviation of the noise must be numeric")
    if (length(mean) > 1 | length(sd) > 1)
        stop("The mean and standard deviation of the noise must be of le
    if (sd < 0)
        stop("The standard deviation of the noise must be positive")
    # (...)
}
```

Documenter

```
#' FuzzyDouble
#'
#' Fuzzy double of a numeric object.
#'
#' Doubles an object with a random noise: a Gaussian
#'   by \code{\link{rnorm}}.
#'
#' @param x A numeric object
#' @param mean The mean noise. Default is 0.
#' @param sd The standard deviation of the noise. Def
#'
#' @return a \code{FuzzyDouble} object which is a dat
#'   columns \code{x} for the input and \code{y} for
#'
#' @seealso \code{\link{plot.FuzzyDouble}},
#'   \code{\link{autoplot.FuzzyDouble}}
```

Réoxygéner

Nettoyer l'environnement

Build Source package

Install and Restart

`?FuzzyDouble`

Méthodes S3

Ecrire un méthode `plot` pour `FuzzyDouble`

```
plot.FuzzyDouble <- function(x, xlab = "x", ylab = "Double",
    ..., LineCol = "red") {
    # xy standard plot
    graphics::plot(x$x, x$y, xlab = xlab, ylab = ylab,
        ...)
    # Add the regression line
    graphics::lines(x$x, 2 * x$x, col = LineCol)
}
```

Remarquer :

- Les `...` et le passage de `xlab` et `ylab`

Méthodes S3

Ecrire un méthode autoplot pour FuzzyDouble

```
autoplot.FuzzyDouble <- function(object, xlab = "x",
    ylab = "Double", ..., LineCol = "red") {
    # ggplot
    thePlot <- ggplot2::ggplot(data = x, ggplot2::aes_(x = ~x,
        y = ~y)) + ggplot2::geom_point() + ggplot2::labs(x = xlab,
        y = ylab) + ggplot2::geom_line(ggplot2::aes_(y = ~2 *
        x), colour = LineCol)
    return(thePlot)
}
```

Documenter

```
#' Plot FuzzyDouble
#'
#' Plot a FuzzyDouble object
#'
#' @param x The \code{\link{FuzzyDouble}} object
#' @param xlab The X-axis label
#' @param ylab The Y-axis label
#' @param ... Extra parameters passed to \code{\link{
#' @param LineCol The color of the line representing
#'
#' @importFrom graphics plot
#' @method plot FuzzyDouble
#' @export
#'
#' @examples
#' plot(FuzzyDouble(1:10))
```

Documenter


```
#' Plot FuzzyDouble
#'
#' Plot a FuzzyDouble object with ggplot2
#'
#' @inheritParams plot.FuzzyDouble
#' @param object The \code{\link{FuzzyDouble}} object
#' @param ... Extra parameters passed to \code{\link{
#'
#' @return A \code{\link{ggplot}} object.
#'
#' @importFrom ggplot2 autoplot
#' @method autoplot FuzzyDouble
#' @export
#'
#' @examples
#' autoplot(FuzzyDouble(1:10))
```

Vérifier

Check détecte que les packages *stats*, *graphics* et *ggplpot2* manquent dans `DESCRIPTION`.

Corriger :

```
Depends: R (>= 3.4.3), graphics, ggplot2
Imports: stats
```

Règles de dépendance

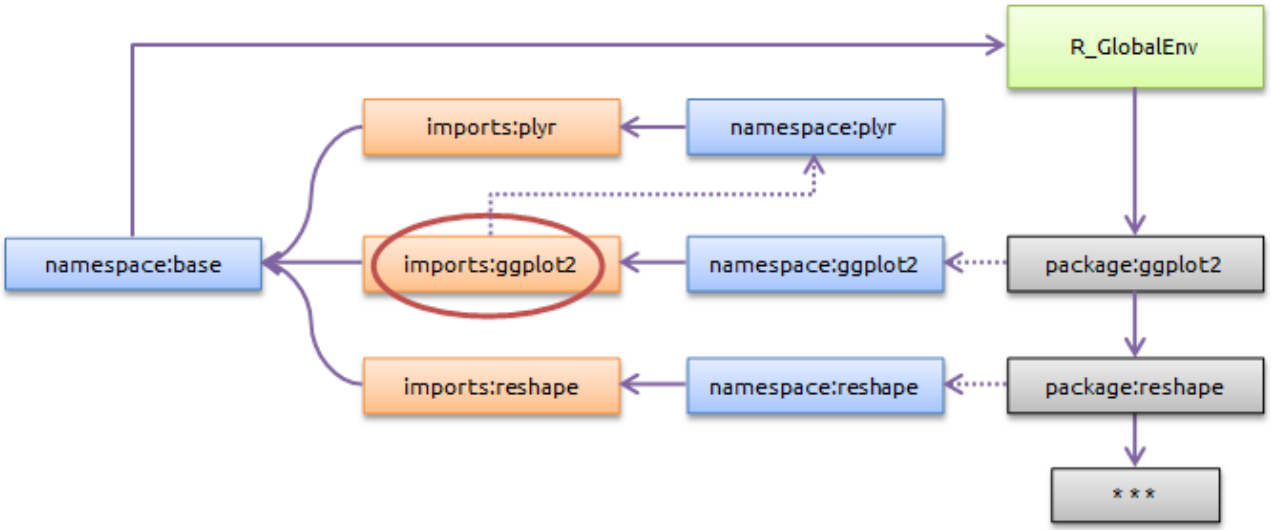

Dans `DESCRIPTION`:

- Imports: *stats* comme *plyr*. Standard.
- Depends: *graphics* comme *reshape* à cause des génériques.

Règles de dépendance

Toute fonction d'un package doit être appelée explicitement: `graphics::plot()`

- Ne pas importer ces fonctions dans l'espace de nom (`@importFrom`).
- Leurs packages doivent être déclarés *Imports* dans `DESCRIPTION`.

Règles de dépendance

Les fonctions publiques du package doivent être exportées (`@export`), y compris les génériques.

Les méthodes S3 ne sont pas exportées mais obligatoirement déclarées (`@method`).

Attention : Roxygen2 ne les déclare que si `@export` est ajouté.

Conséquence : les génériques doivent être importés (`@importFrom`) et leur package déclaré *Depends* dans `DESCRIPTION` pour être exportés.

Etudier `NAMESPACE`

Reste à écrire

La fonction `Multiple(x, n)` avec un paramètre supplémentaire.

`Double(x)` pourrait appeler `Multiple(x, 2)` et lui sous-traiter les vérifications et les calculs.

Une classe `Multiple` dont `n` pourrait être un attribut, ses méthodes `plot` et `autoplot`...

Eric Marcon

Données

Des données peuvent être intégrées au package dans un ou des fichiers RData.

Créer un dossier `/data`

La fonction `use_data()` crée les fichiers:

```
MyData <- 1:100
devtools::use_data(MyData)
```

Documentation des données

Dans `Project.R`:

```
#' My Data
#'
#' A useless dataset.
#'
#' @format A numeric vector
#' @source \url{http://www.ecofog.gf/}
"MyData"
```

Contrôle de source

Objectif

Suivre le développement du package.

Collaborer.

Le rendre accessible sur GitHub.

Bénéficier des outils de GitHub : intégration continue, couverture du code.

Passer le projet sous contrôle de source

A partir d'un projet RStudio existant :

- Passer le projet sous contrôle de version :
  - *Tools /Version Control /Project Setup...*
  - Sélectionner *Git*.
- Créer un dépôt sur GitHub, récupérer son URL : https://github.com/MonCompte/MonDepot.git
- Dans le Terminal de RStudio, exécuter :

```
git remote add origin https://github.com/MonCompte/Mo
git push -u origin master
```

Séance de travail

- Tirer ;
- Modifier ;
- **Vérifier : *Check* pour valider le package.**
- Livrer ;
- Pousser.

Numéros de version

Standard R :

Majeure.Mineure-Patch.Développement

Dans `DESCRIPTION` :

`0.0.0.9000`

- Rétablir le tiret.

Version de développement à partir de 9000, seulement entre deux versions CRAN:

`0.1-0`

NEWS.md

Fichier Markdown pour lister les avancées du projet.

Exemple :

```
# EcoFoG 1.2-1

## Correction de bug

* Modèle Présentation : tricotage Beamer impossible e
  de bout de code. Ajout de `\usepackage{fancyvrb}` d
  `EcoFoGBeamer.tex`.

## Améliorations

* _.gitignore_ dans tous les modèles.
```

Séance de travail

- Tirer ;
- Modifier ;
- Vérifier : *Check* pour valider le package.
- **Mettre à jour la version dans `DESCRIPTION` et compléter `NEWS.md`**
- Livrer ;
- Pousser.

Intégration continue

Travis-CI vérifier le package par un *Check* à chaque livraison.

- Ouvrir un compte sur Travis
- Ajouter le dépôt GitHub du package.

codecov.io mesure la proportion du code exécutée par Travis

- Ouvrir un compte sur *codecov.io*
- Ajouter le dépôt GitHub du package.

travis.yml

Fichier de paramétrage:

```
language: R
sudo: false
cache: packages

r_packages:
 - devtools
 - covr

after_success:
  - Rscript -e 'library(covr); codecov(type ="all")'
```

Badges

Dans `README.md` (package *EricMarcon/SpatDiv*):

```
![stability-wip](https://img.shields.io/badge/
  stability-work_in_progress-lightgrey.svg)

![Travis-CI Build Status](https://travis-ci.org/EricM
 SpatDiv.svg?branch=master)]
 (https://travis-ci.org/EricMarcon/SpatDiv)

![codecov](https://codecov.io/github/EricMarcon/SpatD
  branch/master/graphs/badge.svg)]
  (https://codecov.io/github/EricMarcon/SpatDiv)
```

D'autres badges sur *shields.io*.

Vignette

Intérêt

Les vignettes sont la documentation d'un package.

Nombreux formats possibles :

- entropart : format packagedocs, totalement déporté.
- EcoFoG : format BioConductor, interdit sur CRAN.
- Vignettes *knitr* en PDF...

```
# Liste des vignettes
vignette(package = "ggplot2")
# Ouvrir une vignette
vignette("ggplot2-specs", package = "ggplot2")
```

packagedocs

Installer le package.

Le déclarer dans `DESCRIPTION` :

```
Suggests: packagedocs
```

Mode d'emploi

La documentation doit être écrite dans `vignettes/docs.Rmd`

Une vignette automatique contient l'aide des fonctions.

packagedocs

Initialisation :

```
packagedocs::init_vignettes()
```

Compléter les entêtes de `docs/vignettes/docs.Rmd` et `rd.Rmd` et corriger :

```
navpills: |
  <li class="active"><a href='index.html'>Docs</a></l
  <li><a href='rd.html'>Package Ref</a></li>
  <li><a href='https://github.com/Utilisateur/Depot'>
```

Construction des vignettes

Exécuter :

```
packagedocs::build_vignettes(output_dir = "docs")
```

pour créer les vignettes

Vignettes en ligne

Pousser sur GitHub.

Activer les pages web sur `/docs`.

L'appel aux vignettes dans R renvoie sur le site.

Code C++ et parallélisation

Intérêt

Le code C++ est très rapide mais plus compliqué à écrire et déboguer.

A utiliser seulement en cas de besoin. Exemple : *dbmss*

La parallélisation permet d'éxécuter des tâches longues sur plusieurs processeurs ou ordinateurs.

Le code est plus complexe.

La synchronisation des tâches consomme des ressources.

A utiliser seulement en cas de besoin.

Code C++

Démarrage :

```
devtools::use_rcpp()
```

Dans `Project.R`:

```
#' @useDynLib multiple, .registration = TRUE
#' @importFrom Rcpp sourceCpp
```

Code C++

Le code est dans `/src`. Créer un fichier C++ :

```
#include <Rcpp.h>
using namespace Rcpp;

//' timesTwo
//'
//' Multiplies by 2
//'
//' @param x An integer
//' @export
// [[Rcpp::export]]
int timesTwo(int x) {
   return x * 2;
}
```

Remarquer : la documentation pour *Roxygen*, dont `@export` et

Fonctionnement de Rcpp

Le package *Rcpp* compile le code C++, en fait un programme exécutable (librairie *dll*).

Il crée une fonction R du même nom que la fonction C (étudier `R/RcppExports.R`).

La librairie *dll* est déclarée dans `NAMESPACE` et la fonction R est exportée.

Paralléliser R

Nombreuses techniques disponibles.

Une très simple pour le code R dans le package *parallel*

`parallel::mclapply` remplace `lapply()`

Sans effet sous Windows.

- Test sur RStudio.

Paralléliser C

Package *Rcppparallel*

Fonctionnement similaire à *Rcppp* mais code beaucoup plus complexe.

- Exemple dans *SpatDiv*

Extrêmement efficace, y compris sous Windows.

Problèmes avec CRAN.

Tests unitaires

Intérêt

Tester le code pour vérifier :

- sa syntaxe (le code non exécuté n'est pas vérifié par *Check*) ;
- ses résultats.

Principes :

- exécuter tout le code (couverture = 100%) ;
- comparer les résultats entre eux ou à des références.

Outil

Package *testthat*

```
devtools::use_testthat()
```

Crée les dossiers et modifie `DESCRIPTION`.

`Suggests: testthat`

Ajouter les fichiers de tests dans `tests/testthat`

Exemple de test

Double.R :

```
testthat::context("Double")
# Random integer vector
x <- rpois(10, lambda = 100)
testthat::test_that("Default and integer S3 methods give the same result
    {
        testthat::skip_on_cran()
        testthat::expect_equal(Double(x), Double(as.numeric(x)))
    })
testthat::test_that("Double(integer) is integer", {
    testthat::skip_on_cran()
    testthat::expect_is(Double(x), "integer")
})
```

Ajout de tests

Tester tout le code :

- les tests négatifs :
- les cas rares.

Utiliser codecov.io pour voir le code non couvert.

- Exemple de *entropart*

CRAN

Intérêt

Un package sur CRAN peut être utilisé par tous.

Il peut être publié : *Methods in Ecology and Evolution*, . . . , *The R Journal*.

L'auteur aura des retours d'autres utilisateurs.

Contraintes

Le responsable du package (`role = c("aut", "cre")`) doit répondre aux sollicitations de CRAN.

Le package ne doit générer aucun avertissement, et normalement aucune note.

La vérification sur CRAN est plus exigente :

- plusieurs plateformes ;
- des tests du code C.

Préparation

Vérification OK localement et sur Travis.

Construire la source du package avec la dernière version de R.

Vérifier le package sur :

- Win-Builder : plateforme Windows ;
- The r-hub builder : nombreuses plateformes.

Soumission

Vérifier que la version est à correcte :

- patch = 0 sauf si c'est un patch.
- pas de version de développement.

Soumission sur CRAN.

En cas de rejet, corriger et resoumettre en incrémentant le patch.

Publication

En cas de publication, ajouter un fichier `inst/CITATION`

Exemple de `entropart`

```
citation(package = "entropart")
```

```
##
## To cite entropart in publications use:
##
##   Eric Marcon, Bruno Herault (2015).
##   entropart: An R Package to Measure and
##   Partition Diversity. Journal of
##   Statistical Software, 67(8), 1-26.
##   doi:10.18637/jss.v067.i08
##
## A BibTeX entry for LaTeX users is
##
```