R: Tidyverse

Eric Marcon

02 mai 2018

Manifeste

Approche complète de l'analyse de données

Données bien rangées (*tidy*)

Enchaînement des opérations (%>% de *magrittr*, + de *ggplot2*)

Programmation fonctionnelle (pas orientée objet), optimisée pour les utilisateurs (lisibilité plutôt que performance)

```
library("tidyverse")
vignette("manifesto", package = "tidyverse")
```

Ensemble de packages, appelés par *tidyverse*

Données rectangulaires

Modèle du data frame : une ligne par observation, une colonne par attribut.

Dataframe optimisé : `tibble`

Documentation : `vignette("tibble", package="tibble")`

```
ggplot2::diamonds
```

```
## # A tibble: 53,940 x 10
##    carat cut       color clarity depth table price
##    <dbl> <ord>     <ord> <ord>   <dbl> <dbl> <int>
## 1 0.230 Ideal     E     SI2      61.5  55.0   326
## 2 0.210 Premium   E     SI1      59.8  61.0   326
## 3 0.230 Good      E     VS1      56.9  65.0   327
## 4 0.290 Premium   I     VS2      62.4  58.0   334
## 5 0.310 Good      J     SI2      63.3  58.0   335
## # ... with 5.394e+04 more rows, and 3 more
## #   variables: x <dbl>, y <dbl>, z <dbl>
```

Méthode de travail

Bagarre (*Wrangling*) :

- Importation des données
- Rangement (*Tidy*)
- Transformation

Visualisation

Modélisation : non traitée ici. A lire.

Communication : RMarkdown et sorties graphiques. Lire :

- Graphics for communication
- Top 50 ggplot2 Visualizations

Eric Marcon

Bagarre

Package *readr*

Lecture de fichiers texte variés.

Importation dans un tibble.

Référence

Fichier csv

Fonctions `read_csv()` et `read_csv2()`

Remplacent `read.csv()` et `read.csv2()` de base

Plus rapide que les fonctions originales.

Rangement

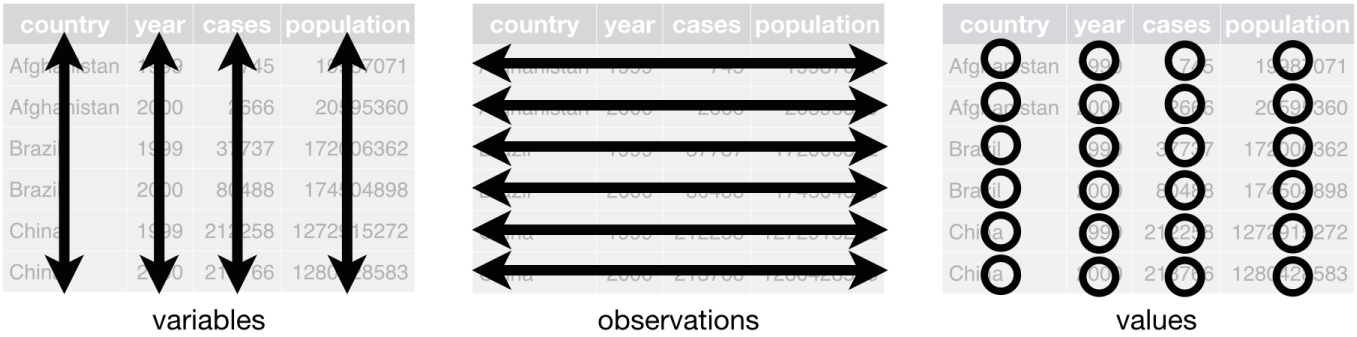

Approche habituelle en écologie (analyse multivariée par exemple)

Si les données sont mal rangées ("pas tidy"), quelques manipulations de base.

Référence

Exemple

Données : inventaire d'une parcelle de Paracou, 4 carrés distincts.

Installer le package EcoFoG à partir de GitHub

```
devtools::install_github("EcoFoG/EcoFoG")
```

Extraire les données

```
library("EcoFoG")
Paracou15 <- as.tibble(Paracou2df("Plot='15' AND CensusYear=2016"))
```

- Afficher Paracou15

Rassemblement (*unite*)

Famille, genre et espèce des arbres sont dans 3 colonnes.

Créer une colonne avec le nom complet de l'espèce.

```
Paracou15 %>%
  unite(col=spName, Family, Genus, Species, remove=FALSE) -> Paracou15
```

- Afficher le résultat.

Le pipeline %>% (`Ctrl + Shift + m`) passe la donnée à la fonction suivante.

La commande classique est :

```
Paracou15 <- unite(data = Paracou15, col = spName,
    Family, Genus, Species, remove = FALSE)
```

Séparation (*separate*)

Opération contraire

country	year	rate
Afghanistan	1999	**745** / 19987071
Afghanistan	2000	**2666** / 20595360
Brazil	1999	**37737** / 172006362
Brazil	2000	**80488** / 174504898
China	1999	**212258** / 1272915272
China	2000	**213766** / 1280428583

table3

country	year	cases	population
Afghanistan	1999	**745**	19987071
Afghanistan	2000	**2666**	20595360
Brazil	1999	**37737**	172006362
Brazil	2000	**80488**	174504898
China	1999	**212258**	1272915272
China	2000	**213766**	1280428583

Rassembler des colonnes (*gather*)

Opération inverse de la création d'un tableau croisé

country	year	cases
Afghanistan	1999	745
Afghanistan	2000	2666
Brazil	1999	37737
Brazil	2000	80488
China	1999	212258
China	2000	213766

country	1999	2000
Afghanistan	745	2666
Brazil	37737	80488
China	212258	213766

table4

Séparer des colonnes (*spread*)

Crée une colonne par modalité d'une variable

country	year	key	value
Afghanistan	1999	cases	745
Afghanistan	1999	population	19987071
Afghanistan	2000	cases	2666
Afghanistan	2000	population	20595360
Brazil	1999	cases	37737
Brazil	1999	population	172006362
Brazil	2000	cases	80488
Brazil	2000	population	174504898
China	1999	cases	212258
China	1999	population	1272915272
China	2000	cases	213766
China	2000	population	1280428583

table2

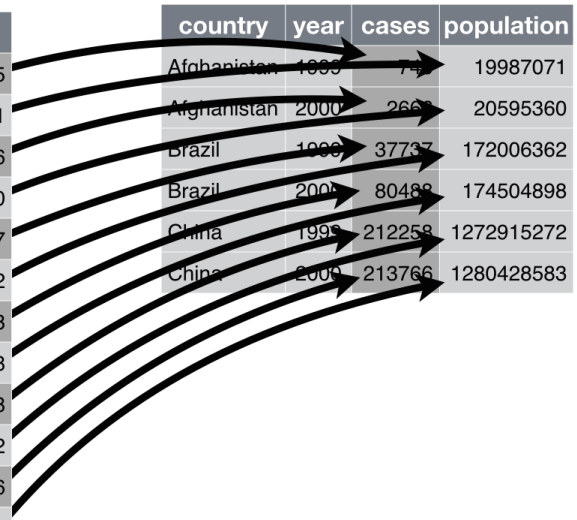

Valeurs manquantes

Les valeurs manquantes explicites (valeur `NA`) peuvent être conservées dans les manipulations ou simplement supprimées avec l'option `na.rm=TRUE`.

`complete(var1, var2)` ajoute des enregistrements pour toutes les combinaisons de var1 et var2 manquantes.

Référence

Transformation

Outils du package *dplyr*

Idée :

- enchaîner les opérations de transformation avec les %>% ;
- les écrire et les tester une à une.

Filtrer les lignes (*filter*)

Filtrer par des conditions sur les différentes variables

```
# Nombre de lignes
Paracou15 %>% count %>% pull
```

```
## [1] 4151
```

```
# Après filtrage
Paracou15 %>% filter(SubPlot == 1 & CodeAlive == TRUE) %>%
    count %>% pull
```

```
## [1] 827
```

Remarquer : `pull()`qui extrait la valeur finale du tibble de taille 1x1 produit par `count()`.

Sélectionner les colonnes (*select*)

Ne retenir que les colonnes intéressantes

```
Paracou15 %>% select(SubPlot:Yfield, Family:Species,
    CircCorr) %>% ncol
```

```
## [1] 10
```

Remarquer : `ncol()` est une fonction de *base*, pas du tidyverse.

Ajouter des variables calculées (*mutate*)

Des colonnes sont ajoutées au tibble

```
(Paracou15Taille <- Paracou15 %>% select(idTree, CircCorr) %>%
    mutate(Diametre = CircCorr/pi))
```

```
## # A tibble: 4,151 x 3
##   idTree CircCorr Diametre
##    <int>    <dbl>    <dbl>
## 1 145370     91.5     29.1
## 2 145371     43.5     13.8
## 3 145372    141       44.9
## 4 145373     52.5     16.7
## 5 145375     99.0     31.5
## # ... with 4,146 more rows
```

Remarquer : le pipe bidirectionnel, les parenthèses pour `print()`

Trier les lignes (*arrange*)

Afficher les plus gros arbres de la parcelle :

```
Paracou15Taille %>% arrange(desc(CircCorr))
```

```
## # A tibble: 4,151 x 3
##   idTree CircCorr Diametre
##    <int>    <dbl>    <dbl>
## 1 145508      332    106
## 2 145326      275     87.5
## 3 145658      273     86.9
## 4 146314      270     85.9
## 5 147958      258     82.1
## # ... with 4,146 more rows
```

Regrouper et résumer

Quel est le diamètre moyen des arbres par famille ?

```
Paracou15 %>% group_by(Family) %>% summarise(Dmean = mean(CircCorr)/pi,
    NbTrees = length(idTree)) %>% arrange(desc(Dmean))
```

```
## # A tibble: 56 x 3
##   Family        Dmean NbTrees
##   <chr>         <dbl>   <int>
## 1 Loganiaceae    54.3       4
## 2 Nyctaginaceae  50.1       2
## 3 Araliaceae     31.9       4
## 4 Goupiaceae     31.7      11
## 5 Vochysiaceae   30.4       6
## # ... with 51 more rows
```

Visualisation

ggplot2

Package destiné à la création de graphiques.

Respecte la grammaire graphique par couches :

```
ggplot(data = <DATA>) +
  <GEOM_FUNCTION>(
     mapping = aes(<MAPPINGS>),
     stat = <STAT>,
     position = <POSITION>
  ) +
  <COORDINATE_FUNCTION> +
  <FACET_FUNCTION>
```

Les données sont obligatoirement un dataframe (un tibble est un dataframe).

Esthétique

L'esthétique désigne ce qui est représenté :

- `x` et `y` (ou `fill` pour un histogramme...)
- transparence, couleur, type de courbe, taille, ... : voir l'aide de chaque `geom_`.

Fonction `aes()` à plusieurs niveaux :

- argument `mapping` de `ggplot()`, hérité par les couches (`geom_`)
- argument `mapping` de chaque couche.

Géométrie

La géométrie est définie par une fonction `geom_xxx` et une esthétique (ce qui est représenté).

```
ggplot(data = diamonds) + geom_point(mapping = aes(x = carat,
    y = price, color = cut)) + scale_colour_brewer(palette = "Set1")
```

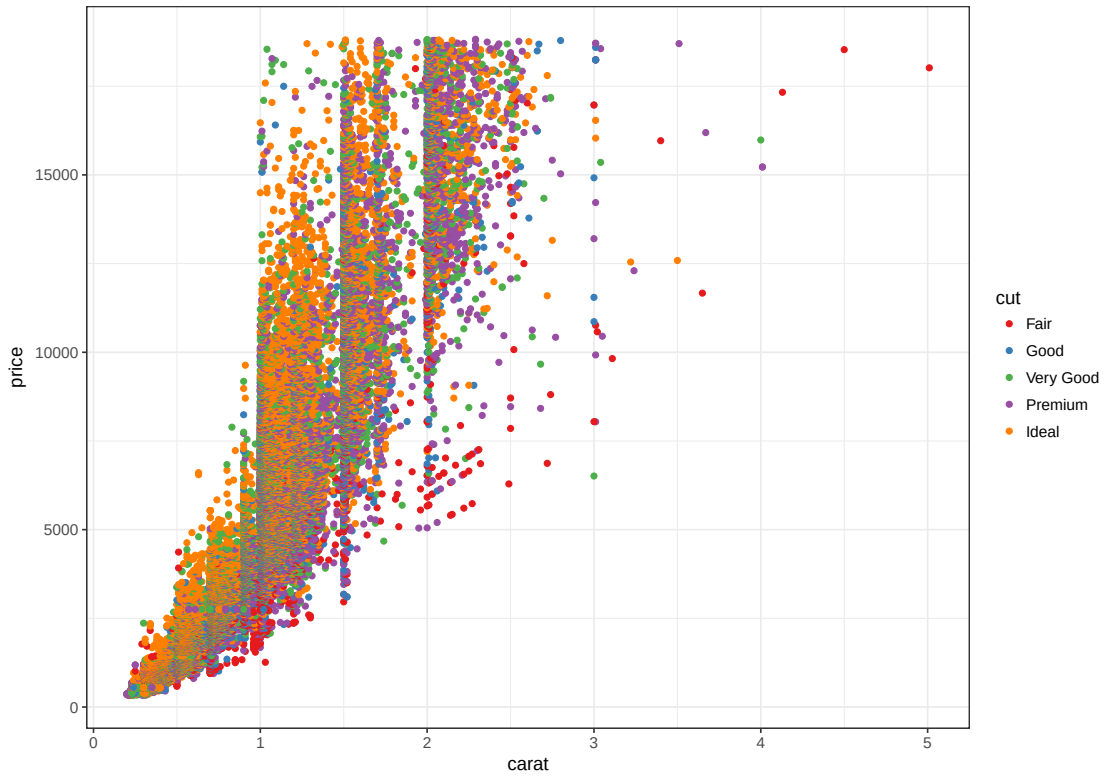

Statistiques

Chaque `geom_` va de pair avec une statistique de transformation des données :

- "identity" pour `geom_point`
- "boxplot" pour `geom_boxplot`
- 20 statistiques disponibles...

Eric Marcon

Statistiques

```
ggplot(data = diamonds) + geom_boxplot(mapping = aes(x = cut,
    y = price))
```

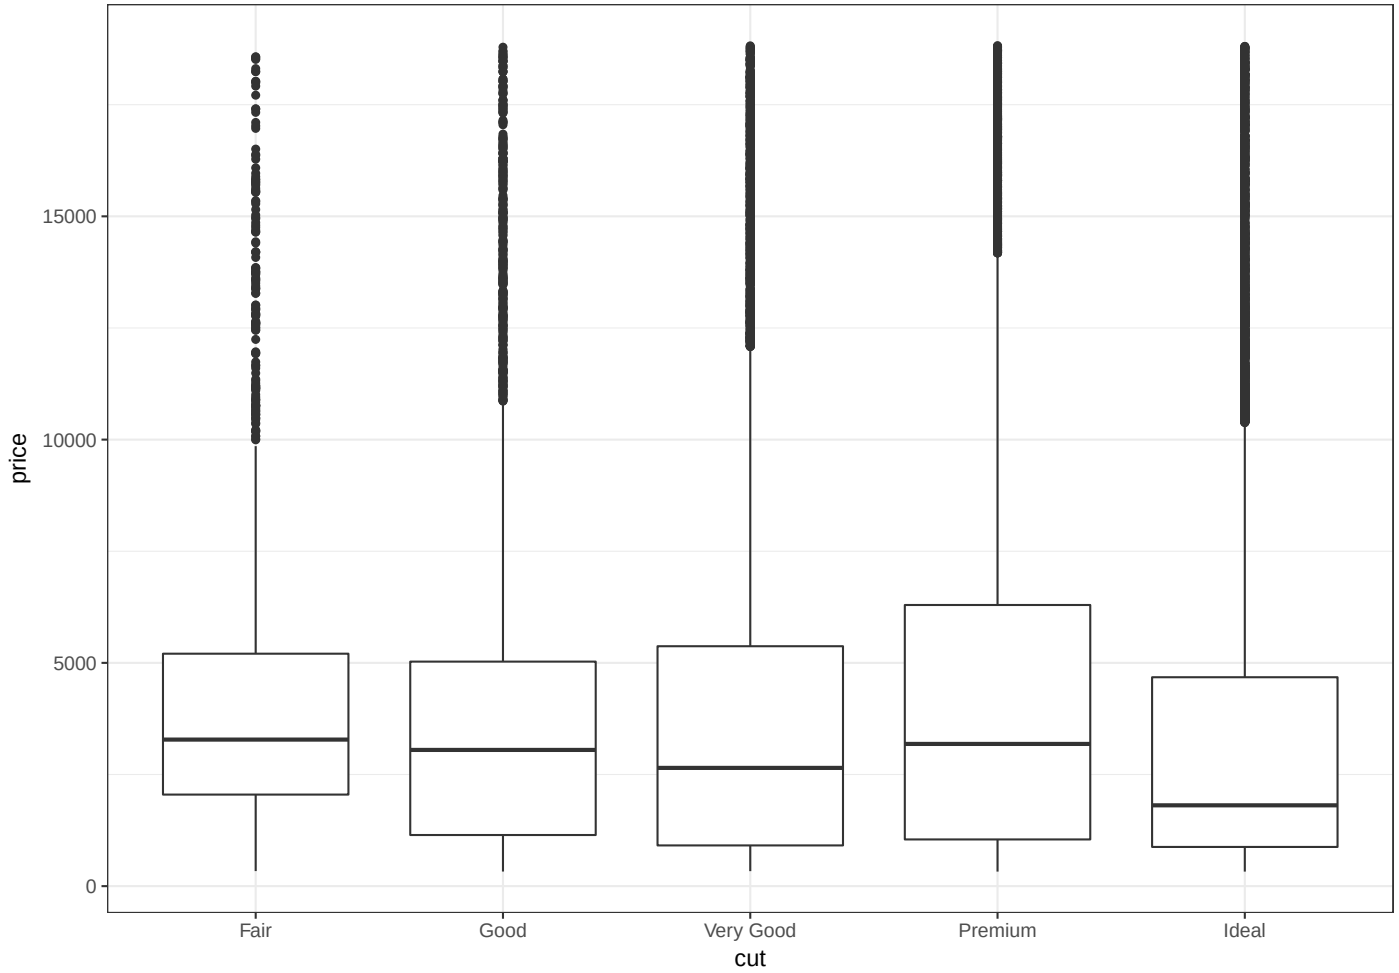

Statistiques

Différent de la transformation de variables (cf. *scale*) : le graphique utilise des données dérivées des données originales.

Chaque statistique a un `geom_` par défaut :

`stat_summary` est interchangeable avec `geom_pointrange`

Statistiques

```
ggplot(data = diamonds) + stat_summary(mapping = aes(x = cut,
    y = depth), fun.ymin = min, fun.ymax = max, fun.y = median)
```

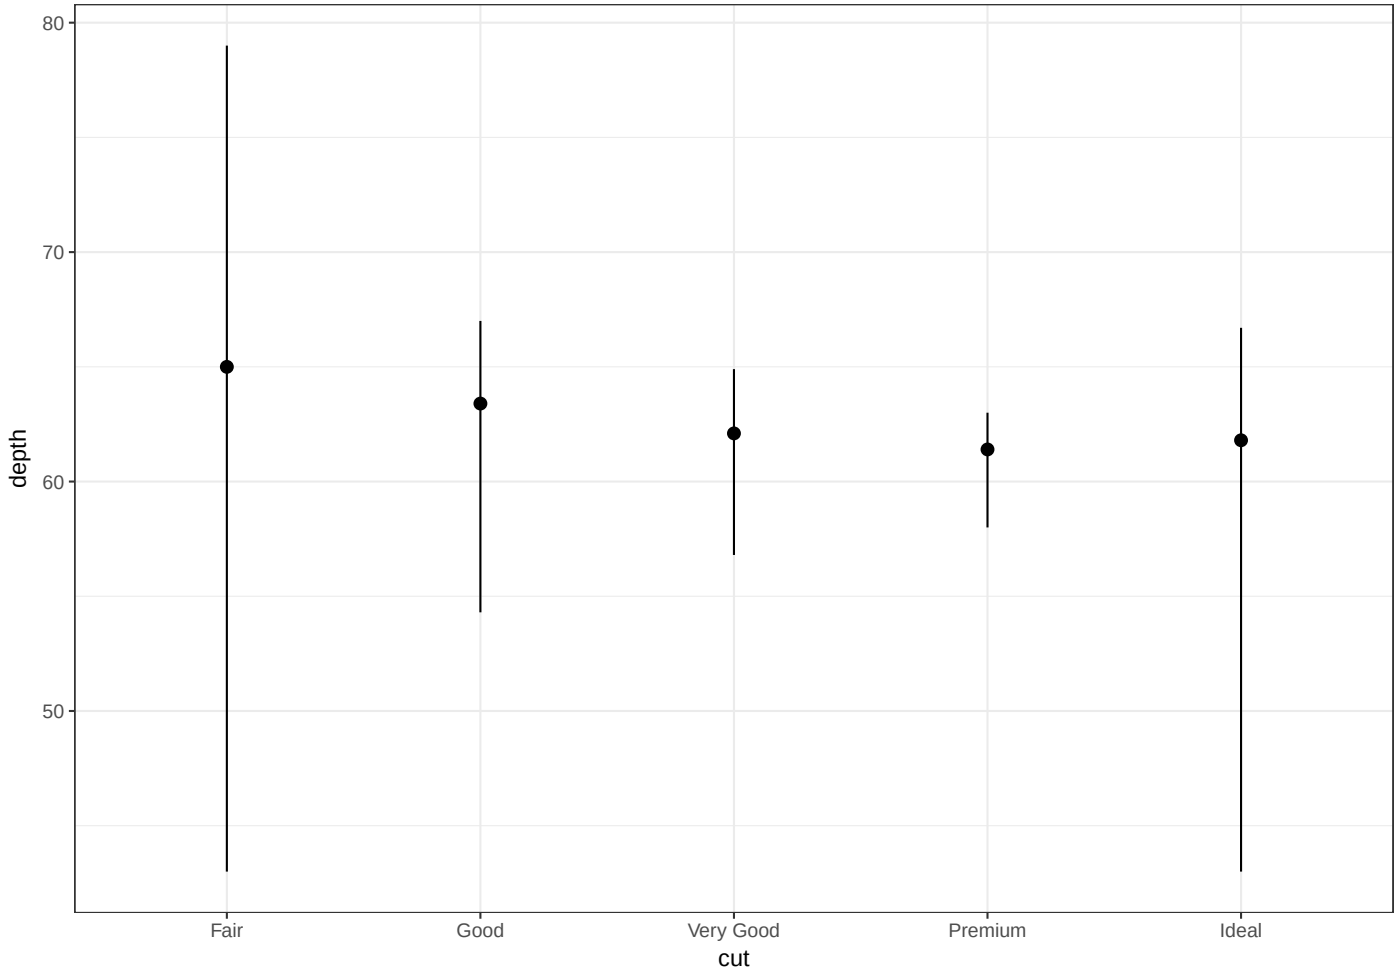

Echelle

Transformation de variable.

```
diamonds %>% filter(carat > 0.5) %>% ggplot(aes(x = carat,
    y = price)) + geom_point() + scale_x_log10() +
    scale_y_log10() + geom_smooth(method = "lm")
```

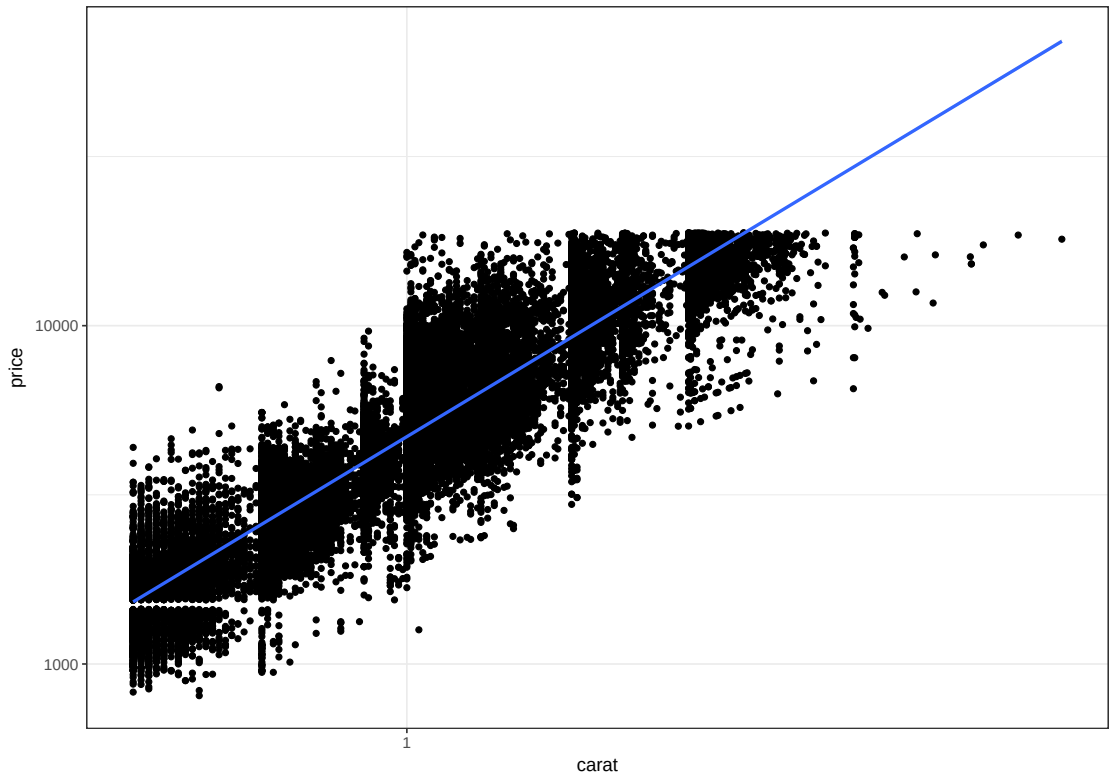

Position

La position définit l'emplacement des objets sur le graphique.

- "identity" en général
- "stack" empile les catégories dans un histogramme
- "jitter" déplace aléatoirement les points dans un `geom_point` pour éviter les superpositions.

Position

```
ggplot(data = diamonds) + geom_bar(mapping = aes(x = cut, fill = color),
  scale_fill_brewer(palette = "Set1")
```

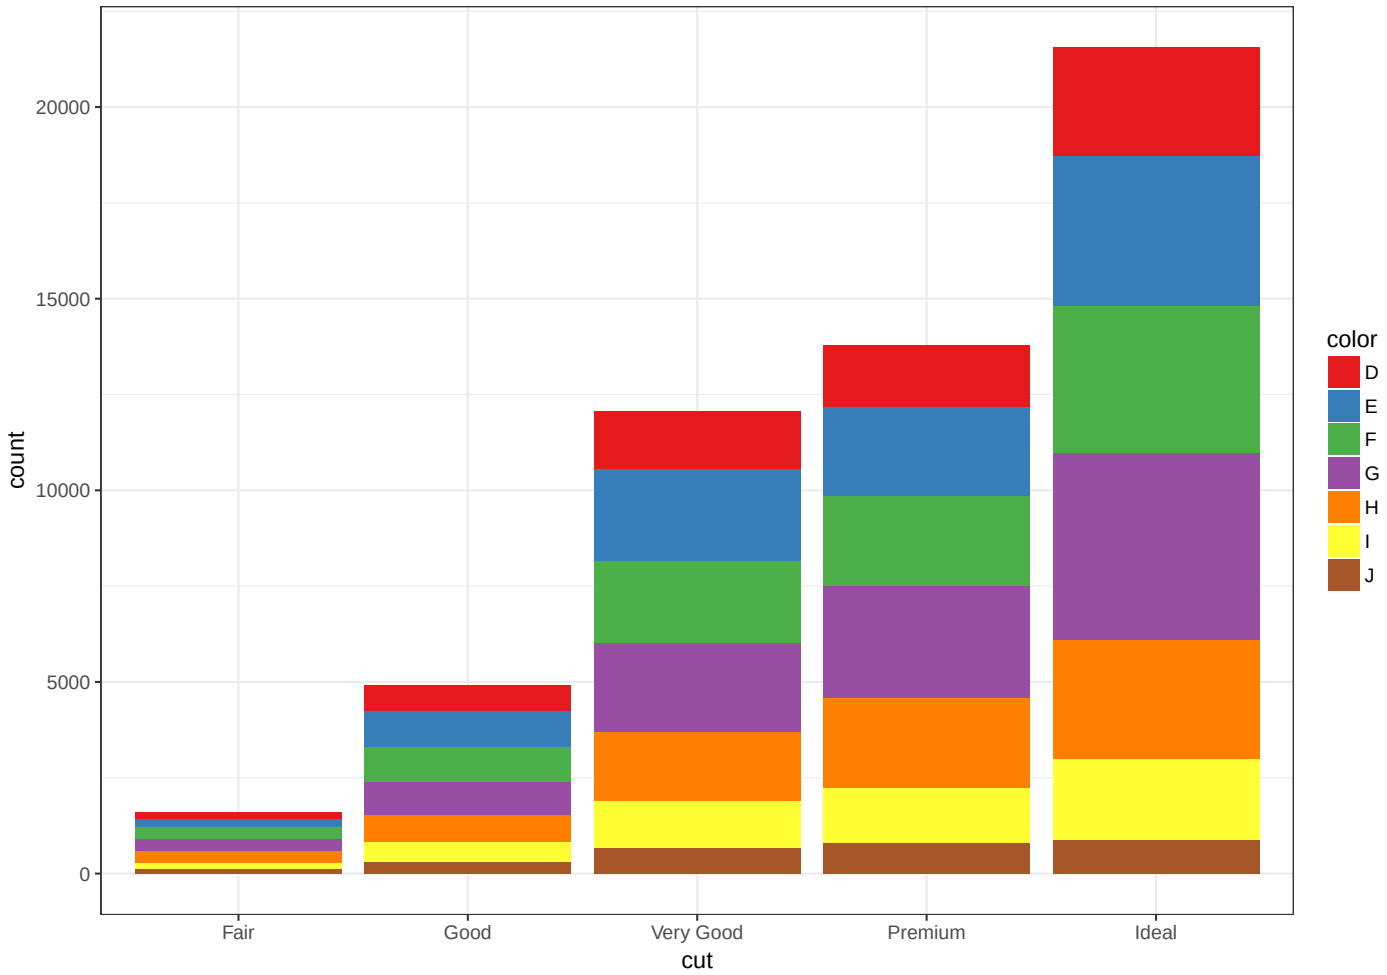

Coordonnées

Système de coordonnées :

- `coord_flip()` intervertit `x` et `y`
- `coord_polar()` : coordonnées polaires
- `coord_trans()` transforme l'affichage des coordonnées (mais pas les données comme `scale_`)
- etc.

Exemple : tracer la carte des wacapous de la parcelle 15.

Coordonnées

```
(P15Map <- Paracou15 %>% filter(Genus == "Eperua") %>%
    ggplot() + geom_point(aes(x = Xfield, y = Yfield,
    size = CircCorr, color = Species)) + coord_fixed())
```

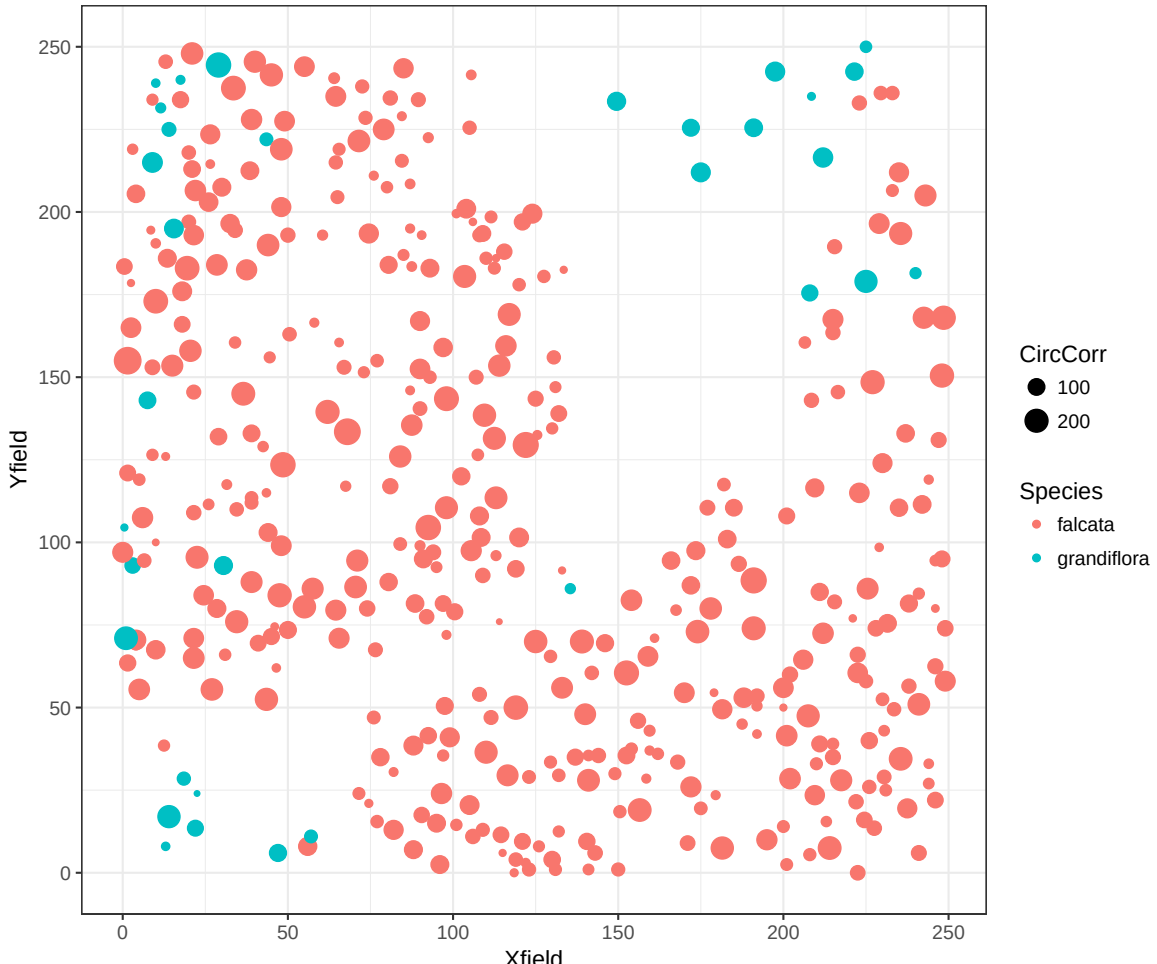

Facettes

Présente plusieurs aspects du même graphique

```
P15Map + facet_wrap(~Species)
```

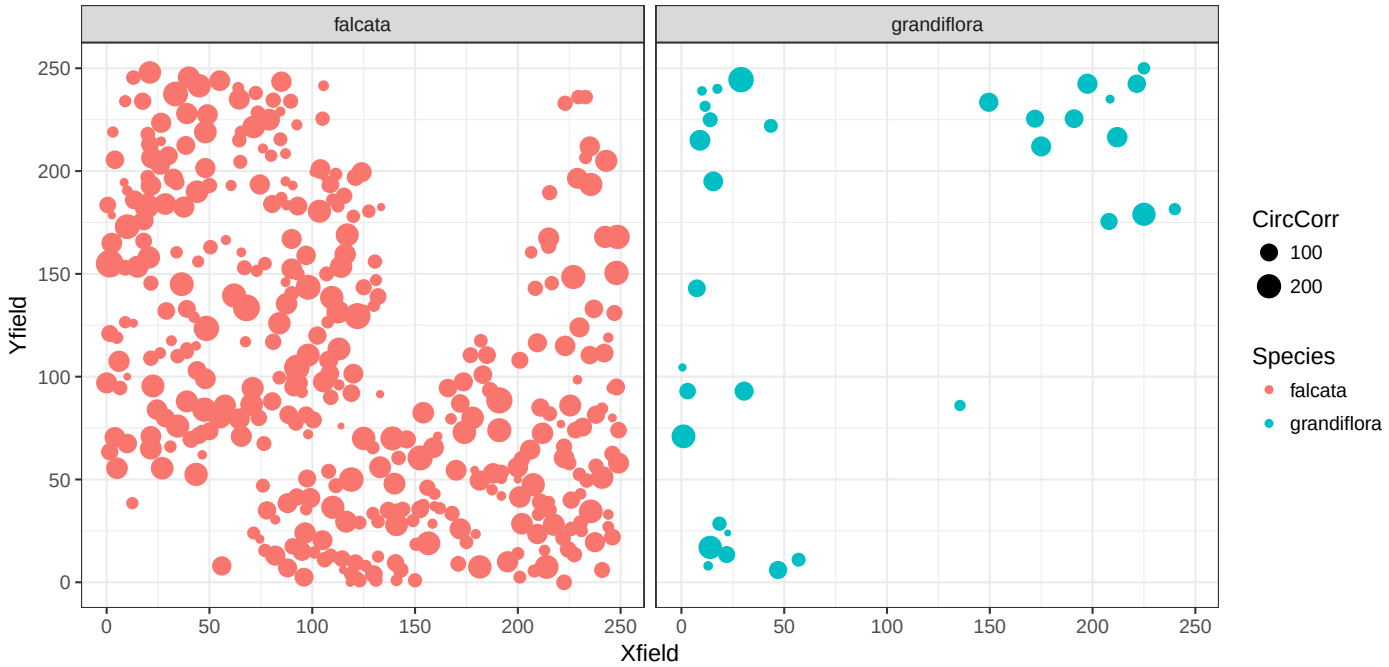

Thèmes

Les thèmes définissent l'aspect des graphiques (hors traitement des données)

Dans ce document : pas de fond grisé dans les graphiques (`theme_bw`), police 12, modifié pour que le fond soit transparent:

```
theme_set(theme_bw(base_size = 12))
theme_update(panel.background = element_rect(fill = "transparent",
    colour = NA), plot.background = element_rect(fill = "transparent",
    colour = NA))
```

Ce sont des options globales, valides pour la session R en cours.

Styles

Possibilité d'enregistrer des paramètres de forme au-delà du thème dans une liste.

Préparation d'un style pour l'impression en noir et blanc, sans cartouches de légende.

```
MyStyle <- list(scale_colour_grey(), theme(legend.position = "none"))
P15Map + MyStyle
```

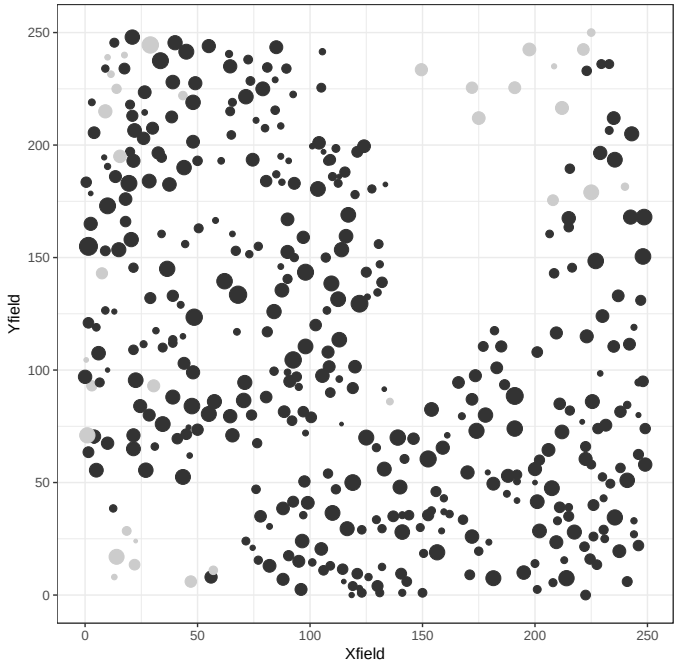

Gestion des couleurs

Les couleurs par défaut sont assez laides.

Utiliser `scale_color_xxx`et `scale_fill_xxx`

Le suffixe `_brewer` est pour utiliser des palettes de ColorBrewer

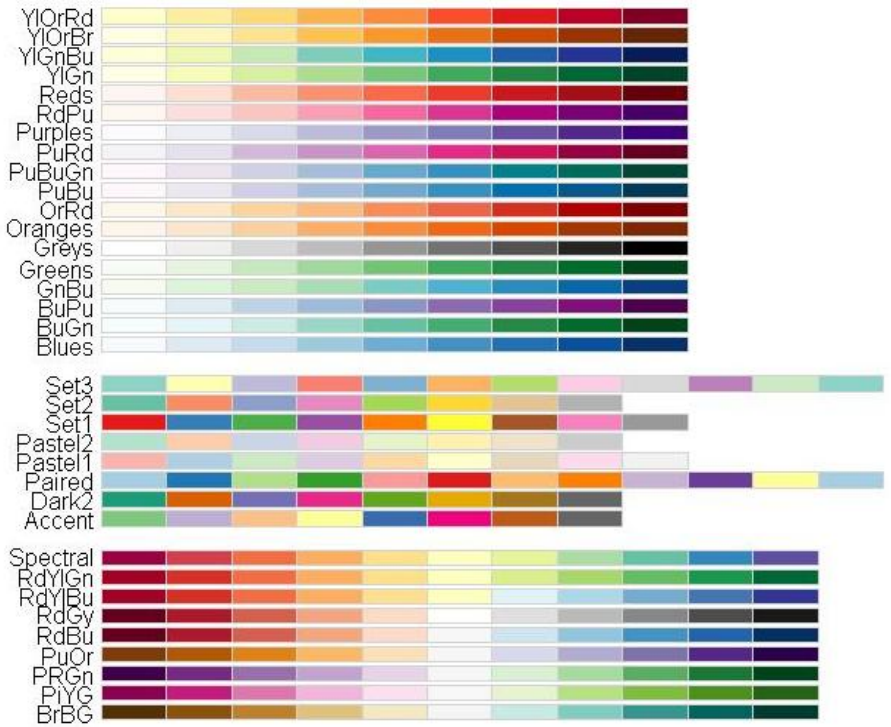

Gestion des couleurs

Le suffixe `_gradient` permet de produire un gradient de couleurs pour les valeurs continues.

Voir les autres fonctions dans l'aide du package.

- Méthode : se créer progressivement des styles (par ex. : couleur et noir et blanc), les enregistrer et les utiliser systématiquement.

autoplot et qplot

`qplot()` mime la syntaxe de `plot()` avec *ggplot2*. Utiliser plutôt la syntaxe native.

`autoplot()` est un générique à étendre par des méthodes S3 pour faire des graphiques ggplot. Exemple:

```
library("entropart")
Paracou618.MC$Ns %>% as.AbdVector %>%
  autoplot(Distribution = "lnorm") + MyStyle
```

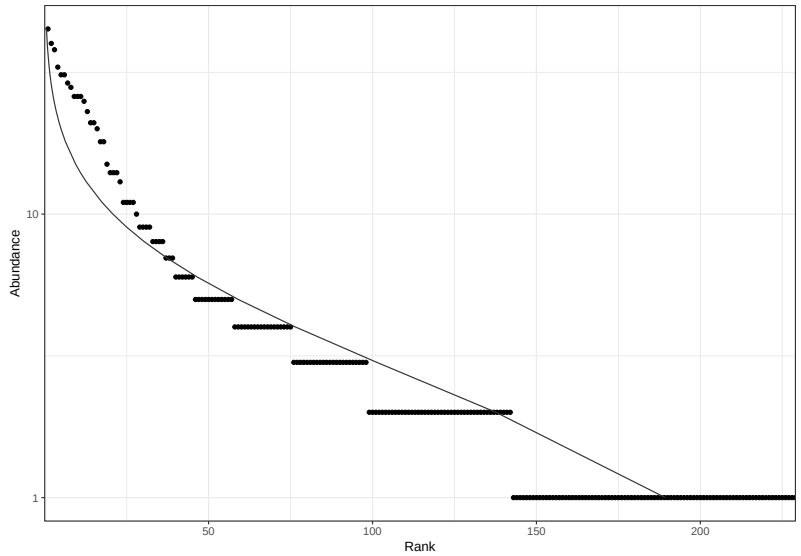

Anti-sèche et extensions

Anti-sèche sur RStudio

De nombreux packages étendent *ggplot2* avec de nouveaux `geom_`. Exemple de *ggraph* :